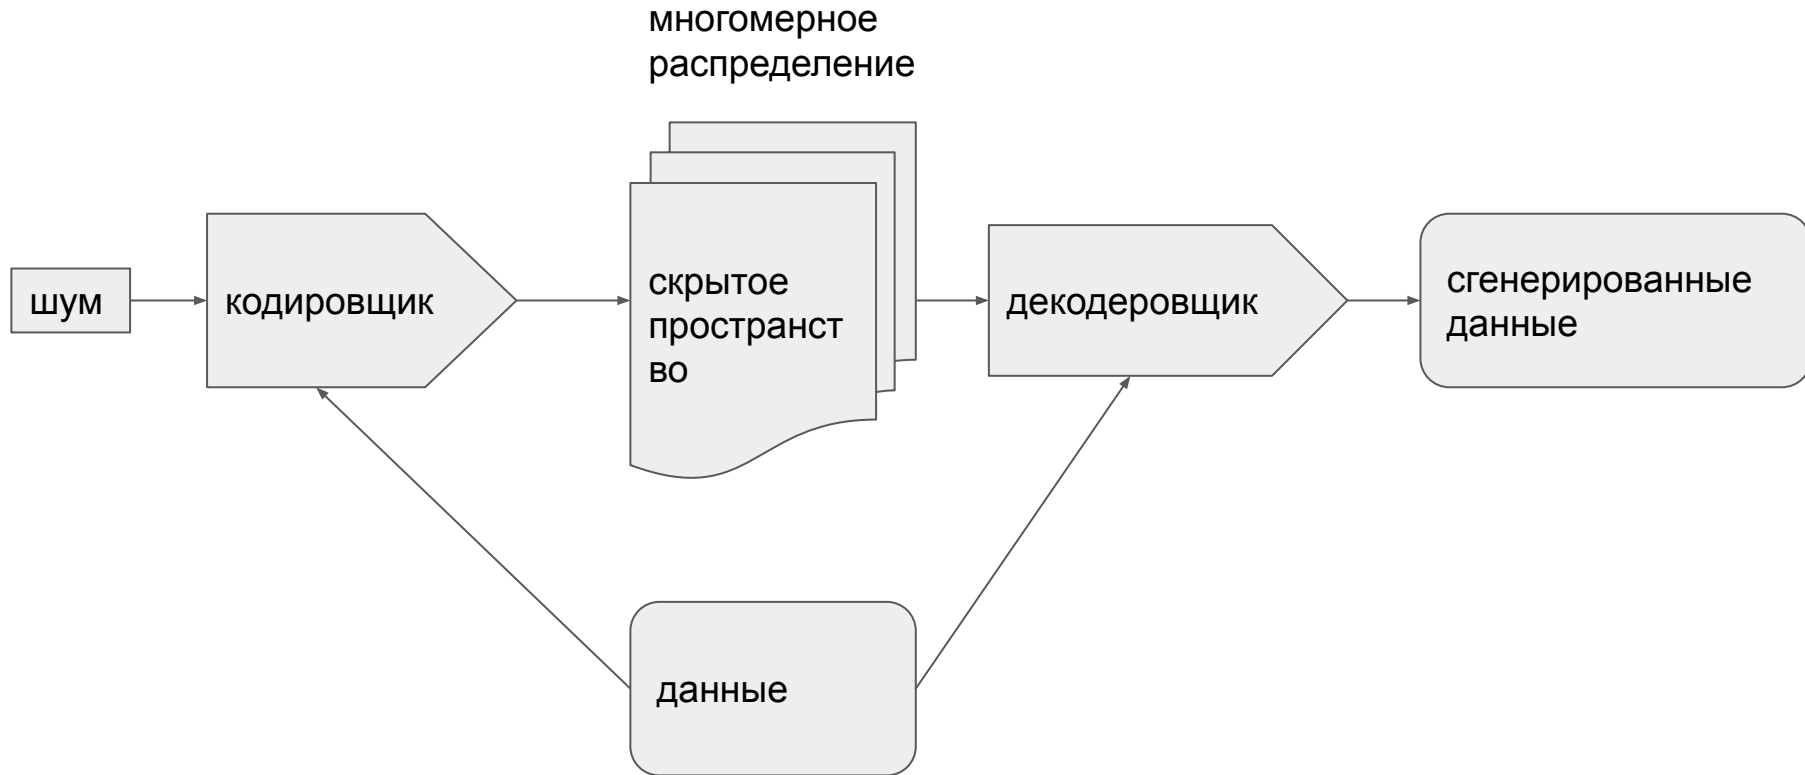


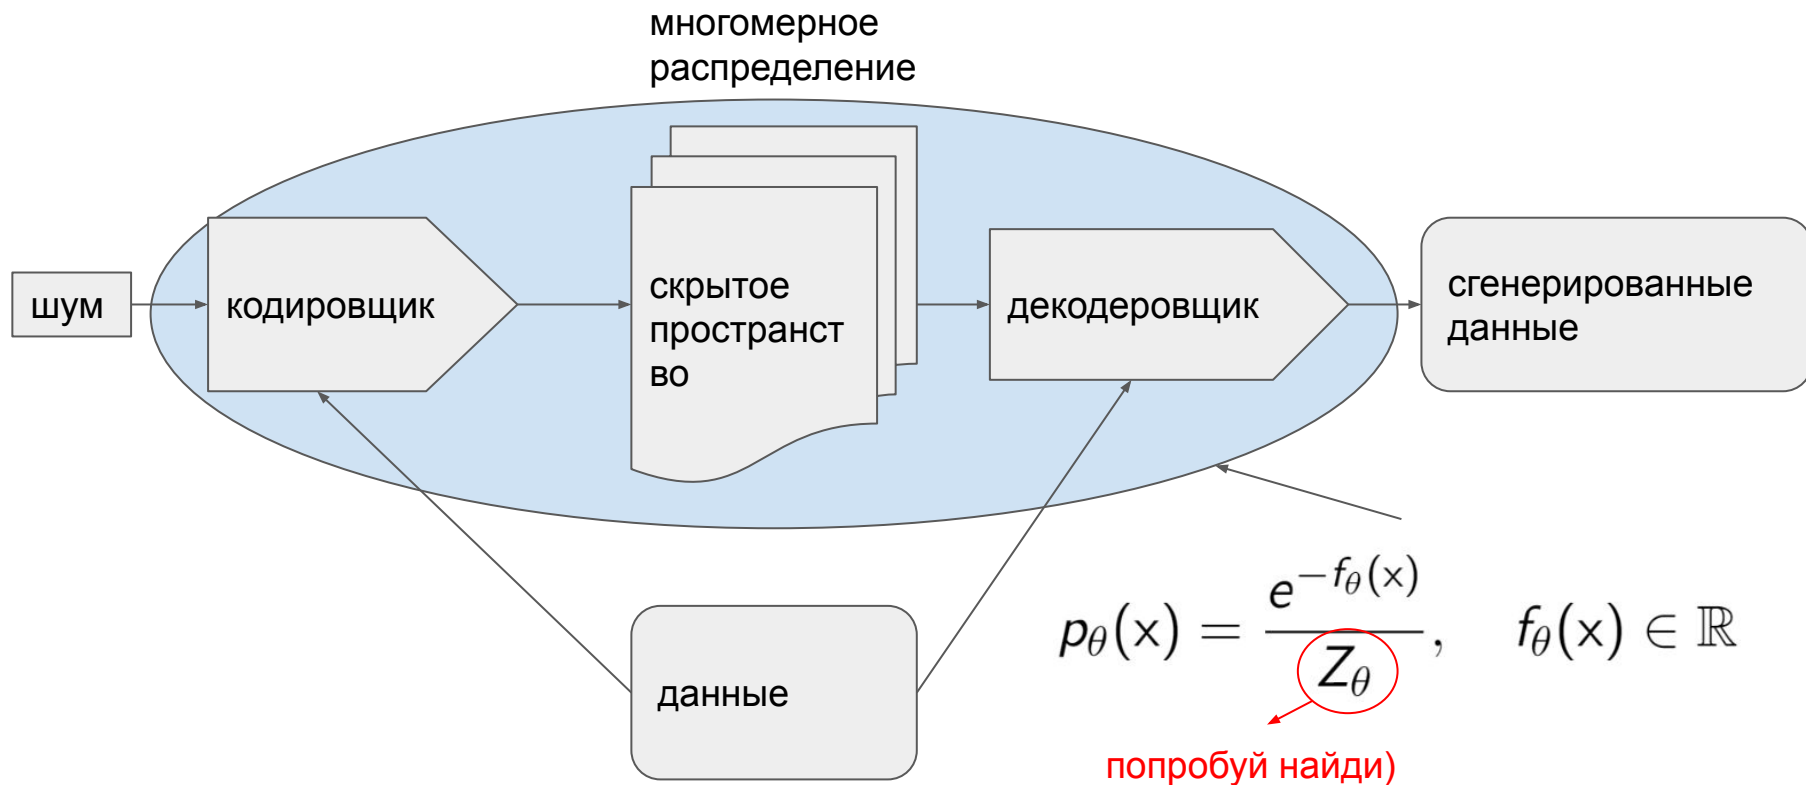
# Дуффузионные модели

начало

# Проблемы GANов и автоэнкодеров?




# Нормализация




# Хватает ли данных?

все данные




что мы собрали  
в датасете

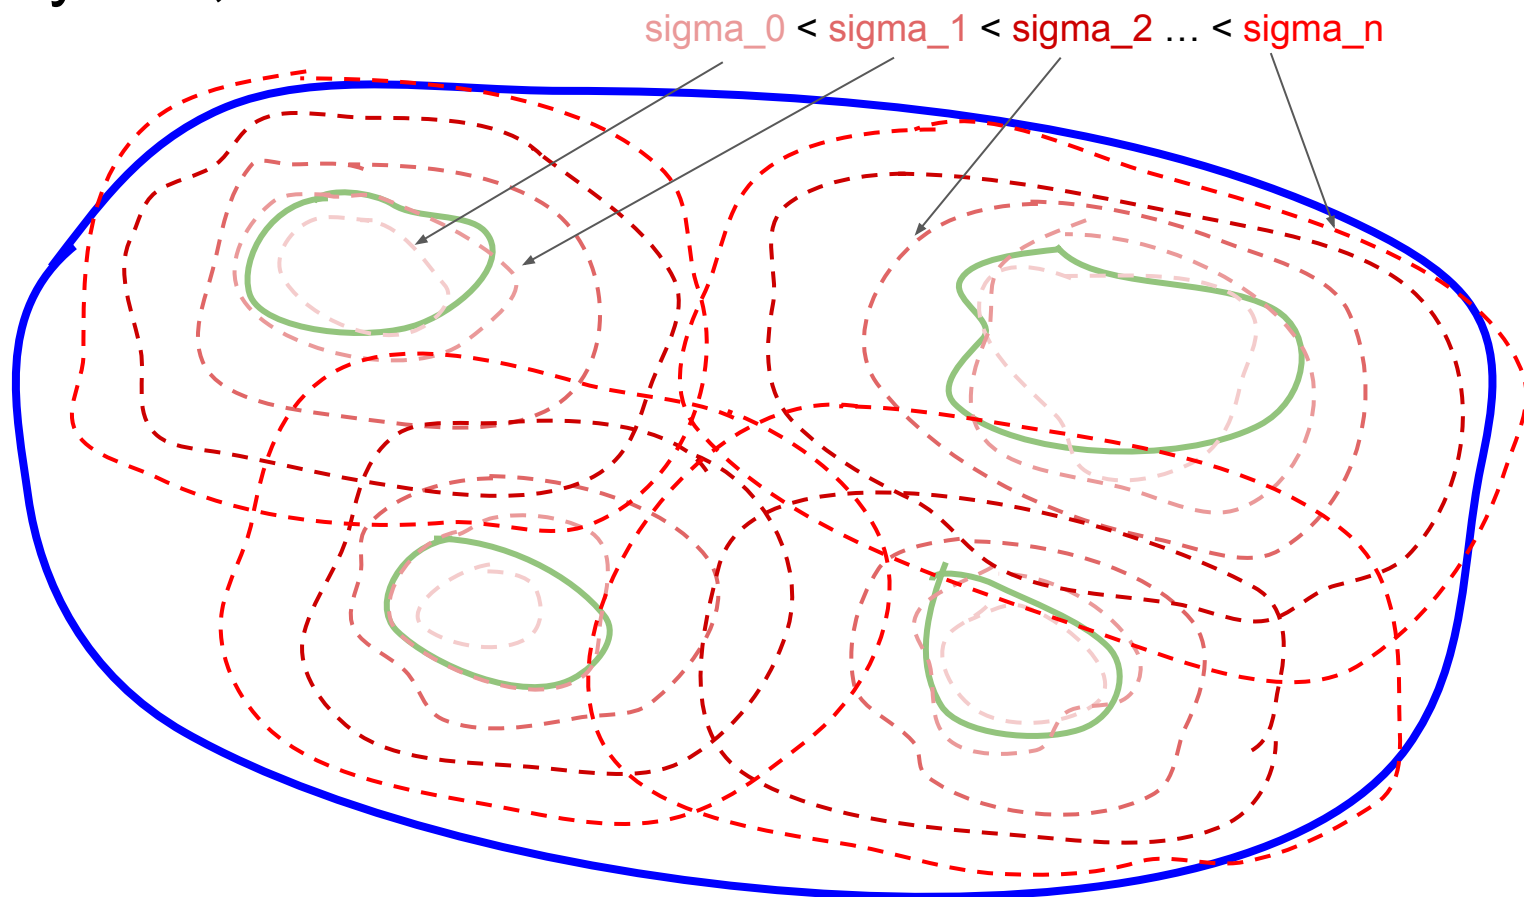
что сможем генерить



хотим генерить



Пошумим, ... ?




Лол... А как же учить? Ааа... Динамика Ланжевена!

датасет  $p(x), \nabla_x \log p(x)$  градиенты данных...  
WHAAT?!?!?!  
$$x_{i+1} \leftarrow x_i + \epsilon \nabla_x \log p(x) + \sqrt{2\epsilon} z_i, \quad i = 0, 1, \dots, K,$$

Где  $z_i \sim \mathcal{N}(0, I)$  и  $K \rightarrow \infty$ .

то, чем шумим




# EBMs

- Energy-Based Models (EBMs)

$$p_{\theta}(\mathbf{x}) = \frac{e^{-f_{\theta}(\mathbf{x})}}{Z_{\theta}}, \quad f_{\theta}(\mathbf{x}) \in \mathbb{R}$$

$$Z_{\theta} = \int e^{-f_{\theta}(\mathbf{x})} d\mathbf{x}$$



- Плюсы Простая модель
- Минусы Сложно обучать  $\theta$  через максимизацию правдоподобия

$$\mathbb{E}_{p_{\text{data}}(\mathbf{x})}[-\log p_{\theta}(\mathbf{x})] = \mathbb{E}_{p_{\text{data}}(\mathbf{x})}[f_{\theta}(\mathbf{x}) + \log Z_{\theta}]$$

# Как же научить EBM's? Score matching !!!

- Score function

$$s(x) = \nabla_x \log p(x)$$

- Score function для EBM модели


$$s_{\theta}(x) = \nabla_x \log p_{\theta}(x) = -\nabla_x f_{\theta}(x) - \underbrace{\nabla_x \log Z_{\theta}}_{=0} = -\nabla_x f_{\theta}(x)$$

- Score matching (Fisher divergence)

$$\mathbb{E}_{p_{\text{data}}(x)}[\|s_{\theta}(x) - \nabla_x \log p_{\text{data}}(x)\|_2^2]$$



# Score matching



$$\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\theta}(\mathbf{x})$$

# Вспомним что хотели шуметь... Denosing SM

- Зашумим данные

$$p_{\sigma}(\tilde{x}) = \int_{\mathbf{x}} q_{\sigma}(\tilde{x}|\mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}, \quad q_{\sigma}(\tilde{x}|\mathbf{x}) = \mathcal{N}(\tilde{x}; \mathbf{x}, \sigma^2 I)$$

- Score matching для зашумленных данных


$$\mathbb{E}_{p_{\sigma}(\mathbf{x})}[\|s_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\sigma}(\mathbf{x})\|_2^2]$$

- Можно переписать как



$$\mathbb{E}_{q_{\sigma}(\tilde{x}|\mathbf{x}) p_{\text{data}}(\mathbf{x})}[\|s_{\theta}(\mathbf{x}) - \nabla_{\tilde{x}} \log q_{\sigma}(\tilde{x}|\mathbf{x})\|_2^2]$$

# Еще раз о том зачем шумим...

- Динамика Ланжевена с трудом переходит между модами




# Иллюстрация как шумим




Учили без шума

$$\mathbb{E}_{p_{\text{data}}(\mathbf{x})}[\|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|_2^2]$$


А теперь с шумом! (Noise Conditional Score Network)


$$\sum_{i=1}^L \lambda(i) \mathbb{E}_{p_{\sigma_i}(\mathbf{x})}[\|\nabla_{\mathbf{x}} \log p_{\sigma_i}(\mathbf{x}) - \mathbf{s}_{\theta}(\mathbf{x}, i)\|_2^2], \quad \lambda(i) = \sigma_i^2$$


# А как это выглядит в итоге?



(a) MNIST



(b) CelebA




(c) CIFAR-10



(a) MNIST



(b) CelebA



(c) CIFAR-10

# Хьюстон, у нас проблемы...

Чтобы всем вышеперечисленным пользоваться, нужно:

- 1) перебирать параметры зашумлений ручками  
 $\mathcal{N}(0, \sigma_1^2 I), \dots, \mathcal{N}(0, \sigma_L^2 I), : \sigma_1 < \dots < \sigma_L$
- 2) учить под каждый параметр нейронную сеть

Но ведь зашумление это же некоторый стохастический процесс!!!

$$dx = f(x, t)dt + g(t)dw$$

функция дрейфа

коэф. диффузии

винеровский процесс

А решения этого уравнения и есть наши  $\mathcal{N}(0, \sigma_1^2 I), \dots, \mathcal{N}(0, \sigma_L^2 I), : \sigma_1 < \dots < \sigma_L$

И как же выбрать ...

$$dx = f(x, t)dt + g(t)dw$$



выбери подходящую функцию



этот выбор определяет судьбу модели ...

$$\mathcal{N}(0, \sigma_1^2 I), \dots, \mathcal{N}(0, \sigma_L^2 I), : \sigma_1 < \dots < \sigma_L$$



# А как из шума получить данные в непрерывном мире?

это знаем


## Reverse SDE

[Anderson, 1982] The Reverse SDE of forward SDE looks like as follow:

$$dx = [f(x, t) - g^2(t) \nabla_x \log p(x(t))]dt + g(t)dw$$

а как посчитать градиенты?  
да мы уже умеем (Score  
Matching)

# В общем виде диффузионки



# Forward

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I})$$


$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1})$$



$\mathbf{x}_0$



$\mathbf{x}$



$\mathbf{x}_T$

# Faster forward

↓

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$
$$\{\beta_t \in (0, 1)\}_{t=1}^T \quad \alpha_t = 1 - \beta_t \quad \bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$
$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$



$\mathbf{x}_0$



$\mathbf{x}_T$

# Faster forward

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1} =$$

$$x_{t-1} = \sqrt{\alpha_{t-1}} x_{t-2} + \sqrt{1 - \alpha_{t-1}} \epsilon_{t-2}$$

$$= \sqrt{\alpha_t \alpha_{t-1}} x_{t-2} + \sqrt{\alpha_t (1 - \alpha_{t-1})} \epsilon_{t-2} + \sqrt{1 - \alpha_t} \epsilon_{t-1} =$$

$$\bar{\epsilon}_{t-2} \in N\left(0, \left(\sqrt{1 - \alpha_t}\right)^2 + \left(\sqrt{1 - \alpha_{t-1}}\right)^2\right)$$

$$= \sqrt{\alpha_t \alpha_{t-1}} x_{t-1} + \sqrt{1 - \alpha_t \alpha_{t-1}} \bar{\epsilon}_{t-2} =$$

$$= \sqrt{\alpha_t \alpha_{t-1} \alpha_{t-2}} x_{t-3} + \sqrt{1 - \alpha_t \alpha_{t-1} \alpha_{t-2}} \bar{\epsilon}_{t-3} =$$

$$= \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$$

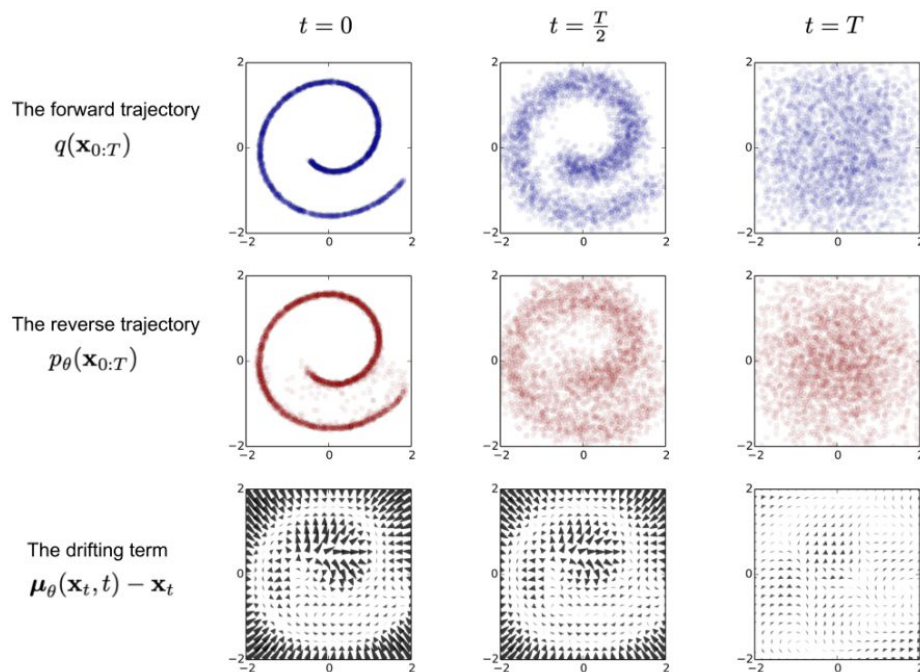
## Faster forward

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \longrightarrow q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

# Reverse

будем предсказывать  
нейронкой

$$p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) \quad p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$



это  $\beta$  из forward, его  
мы задаем сами

# Reverse

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}(\mathbf{x}_t, \mathbf{x}_0), \tilde{\boldsymbol{\beta}}_t \mathbf{I})$$

$$\begin{aligned} q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) &= q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)} \\ &\propto \exp \left( -\frac{1}{2} \left( \frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1})^2}{\beta_t} + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \\ &= \exp \left( -\frac{1}{2} \left( \frac{\mathbf{x}_t^2 - 2\sqrt{\alpha_t} \mathbf{x}_t \mathbf{x}_{t-1} + \alpha_t \mathbf{x}_{t-1}^2}{\beta_t} + \frac{\mathbf{x}_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 \mathbf{x}_{t-1} + \bar{\alpha}_{t-1} \mathbf{x}_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \\ &= \exp \left( -\frac{1}{2} \left( \left( \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{x}_{t-1}^2 - \left( \frac{2\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right) \right) \end{aligned}$$

$$f(x) = e^{ax^2 + bx + c},$$

$$\text{где } a = -\frac{1}{2\sigma^2}, \quad b = \frac{\mu}{\sigma^2}, \quad c = -\left( \ln \sigma + \frac{1}{2} \ln 2\pi + \frac{1}{2} \frac{\mu^2}{\sigma^2} \right)$$



# Reverse

$$\alpha_t = 1 - \beta_t \text{ and } \bar{\alpha}_t = \prod_{i=1}^T \alpha_i$$

$$\tilde{\beta}_t = 1 / \left( \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) = 1 / \left( \frac{\alpha_t - \bar{\alpha}_t + \beta_t}{\beta_t(1 - \bar{\alpha}_{t-1})} \right) = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t$$

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \left( \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) / \left( \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right)$$

$$= \left( \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t$$

$$= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0$$

# Reverse

$$\frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \boxed{\mathbf{x}_0} \longleftarrow \mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_t)$$

$$\tilde{\mu}_t = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_t)$$

$$= \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_t \right)$$

можно считать имея  $x_t$  и предсказывая  $\epsilon_t$

# Reverse: variational lower bound

$$p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) \longrightarrow -\log p_{\theta}(\mathbf{x}_0)$$

ХОТИМ ВЫЧИСЛ  
и минимизирова  $p_{\theta}(\mathbf{x}_0)$   
(т.е. максимизировать макс.  
правдоподобие)

$$-\log p_{\theta}(\mathbf{x}_0) \leq -\log p_{\theta}(\mathbf{x}_0) + \boxed{D_{\text{KL}}(q(\mathbf{x}_{1:T}|\mathbf{x}_0) || p_{\theta}(\mathbf{x}_{1:T}|\mathbf{x}_0))}$$

>0

*variational lower bound*: минимизируя что-то большее, меньшая часть также будет уменьшаться

$$\begin{aligned} &= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_{\mathbf{x}_{1:T} \sim q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[ \log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})/p_{\theta}(\mathbf{x}_0)} \right] \\ &= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_q \left[ \log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} + \log p_{\theta}(\mathbf{x}_0) \right] \\ &= \boxed{\mathbb{E}_q \left[ \log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} \right]} = L_{\text{VLB}} \end{aligned}$$

# Reverse

константа-здесь нет  
обучаемых параметров

отдельно получаемый  
декодер

а вот это надо учить,  
каждое слагаемое-новая  
сеть (но так не хочется)

$$\begin{aligned}
 L_{\text{VLB}} &= \mathbb{E}_{q(\mathbf{x}_{0:T})} \left[ \log \frac{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right] \\
 &= \mathbb{E}_q \left[ \log \frac{\prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
 &= \mathbb{E}_q \left[ -\log p_\theta(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
 &= \mathbb{E}_q \left[ -\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[ -\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \left( \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \cdot \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} \right) + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[ -\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[ -\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{q(\mathbf{x}_1 | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[ \log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \\
 &= \underbrace{\mathbb{E}_q \left[ D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T)) \right]}_{L_T} + \underbrace{\sum_{t=2}^T D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}_{L_0}
 \end{aligned}$$

# Reverse

$$L_t = D_{\text{KL}}(q(\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_t | \mathbf{x}_{t+1})) \quad 1 \leq t \leq T-1$$

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t)) \longrightarrow \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right)$$

$$\begin{aligned} L_t &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[ \frac{1}{2 \|\boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t)\|_2^2} \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[ \frac{1}{2 \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_t \right) - \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right) \right\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[ \frac{(1 - \alpha_t)^2}{2 \alpha_t (1 - \bar{\alpha}_t) \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \|\boldsymbol{\epsilon}_t - \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[ \frac{(1 - \alpha_t)^2}{2 \alpha_t (1 - \bar{\alpha}_t) \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \|\boldsymbol{\epsilon}_t - \boldsymbol{\epsilon}_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}_t, t)\|^2 \right] \end{aligned}$$



# Формула Байеса

**Формула Байеса:**

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)},$$

где

$P(A)$  — априорная вероятность гипотезы  $A$  (смысл такой терминологии см. ниже);

$P(A | B)$  — вероятность гипотезы  $A$  при наступлении события  $B$  (апостериорная вероятность);

$P(B | A)$  — вероятность наступления события  $B$  при истинности гипотезы  $A$ ;

$P(B)$  — полная вероятность наступления события  $B$ .

# Новая математика

- марковские цепи
- стохастические уравнения
- винеровский процесс
- energy base models
- score matching



# А что почитать?

- 1) <https://arxiv.org/pdf/2006.11239.pdf> - 2020 год. Первая статья по диффузионкам, привлечшая большое внимание.
- 2) <https://arxiv.org/pdf/2105.05233.pdf> - 2021 год. Та самая "Diffusion models beat GANs on image synthesis" от авторов 3 статьи. Там всякие эвристики + classifier guidance.
- 3) <https://arxiv.org/pdf/2011.13456.pdf> - 2021 год. Про связь диффузии и score matching.
- 4) <https://arxiv.org/pdf/2010.02502.pdf> - изначально 2021 год. DDIM sampling.
- 5) <https://arxiv.org/pdf/2106.15282.pdf> - 2021 год. Каскадная диффузия с upsampling-ом.
- 6) <https://arxiv.org/pdf/2112.10752.pdf> - 2022 год. Статья по Stable Diffusion.
- 7) <https://arxiv.org/pdf/2201.09865.pdf> - 2022 год. Inpainting с помощью предобученной диффузионки.
- 8) <https://arxiv.org/pdf/2207.12598.pdf> - 2022 год. Classifier-free guidance.

<https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>

<https://www.youtube.com/watch?v=pElwO-2vyus>